

Documentation du Dataset – store_data

Présentation générale

Le dataset **store_data** est un jeu de données de vente au détail (retail). Il contient l'historique des commandes passées par des clients dans un magasin fictif (Superstore), avec des informations sur les produits, les clients, les régions, les ventes et la rentabilité.

Point d'attention pour le chargement en pandas :

```
df = pd.read_csv("Sample - Superstore.csv", encoding="latin-1")
```

Sans préciser l'encodage, tu risques une erreur `UnicodeDecodeError` .

Dictionnaire des colonnes

Colonne	Type attendu	Description	Exemple
Row ID	int	Identifiant unique de la ligne (pas de la commande)	1
Order ID	string	Identifiant de la commande (peut se répéter si plusieurs produits)	CA-2017-152156
Order Date	date	Date à laquelle la commande a été passée	08/11/2017
Ship Date	date	Date à laquelle la commande a été expédiée	11/11/2017
Ship Mode	string (catégorielle)	Mode de livraison	Standard Class, First Class, Second Class, Same Day
Customer ID	string	Identifiant unique du client	CG-12520
Customer Name	string	Donnée personnelle — nom complet du client	Claire Gute
Segment	string (catégorielle)	Segment de clientèle	Consumer, Corporate, Home Office

Colonne	Type attendu	Description	Exemple
Country	string	Pays de livraison	United States
City	string	Ville de livraison	Henderson
State	string	État de livraison	Kentucky
Postal Code	int	Code postal	42420
Region	string (catégorielle)	Grande région géographique	South, West, East, Central
Product ID	string	Identifiant unique du produit	FUR-BO-10001798
Category	string (catégorielle)	Catégorie de produit	Furniture, Office Supplies, Technology
Sub-Category	string (catégorielle)	Sous-catégorie de produit	Bookcases, Chairs, Phones...
Product Name	string	Nom complet du produit	Bush Somerset Collection Bookcase
Sales	float	Montant total de la vente (en \$)	261.96
Quantity	int	Quantité commandée	2
Discount	float	Taux de remise appliqué (0 à 1)	0.20
Profit	float	Marge dégagée sur la vente (peut être négative)	41.91

Points de vigilance connus sur ce dataset

Ces éléments sont **volontairement présents** dans le dataset et constituent la matière de ton travail de nettoyage et de profiling :

- **Valeurs manquantes possibles** sur certaines colonnes
- **Doublons potentiels** au niveau des lignes
- **Dates au format texte**,
- **Profit** peut être négatif
- **Order ID n'est pas une clé unique de ligne** — plusieurs lignes peuvent partager le même **Order ID** si la commande contient plusieurs produits. La vraie clé unique de ligne est **Row**

ID .

- **Customer Name** est la seule donnée à caractère personnel du dataset → c'est elle qui sera traitée dans l'étape RGPD (pseudonymisation/anonymisation).
-